

Odločitvena drevesa in pravila

Ljupčo Todorovski

Univerza v Ljubljani, Fakulteta za upravo
Institut Jožef Stefan, Odsek za tehnologije znanja (E-8)

Marec 2020

Pregled predavanja

Odločitvena drevesa

- Algoritem za učenje dreves *TDIDT*
- Sprotno in naknadno rezanje dreves
- Kontrola pristranskosti in variance

Odločitvena pravila

- Algoritem za učenje posameznih pravil
- Prekrivni algoritem za učenje množice pravil
- Kontrola pristranskosti in variance

Zgradba odločitvenih dreves

Notranje vozlišče

Testira vrednost izbrane napovedne spremenljivke X , npr. $X_1 < 0.5171$


Veje

Ustrezajo izidom testa, npr. *True* in *False*

Končno vozlišče


Poda napoved ciljne spremenljivke Y , npr. $\hat{Y} = 0.39$

Primer regresijskega drevesa



$$Y = (1 + X_1 + X_1 X_2)/3 + \mathcal{N}(0, 0.05), D_i = [0, 1], i = 1..2, D_Y = [0, 1]$$

Primer klasifikacijskega drevesa




$Y = I((1 + X_1 + X_1X_2)/3 \geq 0.5)$, $D_i = [0, 1]$, $i = 1..2$, $D_Y = \{0, 1\}$
zamenjamo vrednost Y 0.05 naključno izbranim primerom


Napoved odločitvenega drevesa za podan primer

- Začni v korenskem vozlišču
- Ponavljaj dokler si v notranjem vozlišču
 - Opravi test notranjega vozlišča
 - Sledi veji, ki ustreza izidu opravljenega testa do novega vozlišča
- Uporabi končno vozlišče za napoved

Napovedi regresijskega drevesa



Napovedi klasifikacijskega drevesa



Algoritem $TDIDT(S) = DecisionTree$

TDIDT: Top-Down Induction of Decision Trees

```
function  $TDIDT(S)$   
  if  $Impurity(S) = 0$   
    return  $DecisionTree(leaf : S)$   
   $Split = SelectOptimal(S)$   
   $\{S_1, S_2, \dots S_s\} = Partition(S, Split)$   
  for  $i = 1$  to  $s$  do  
     $t_i = TDIDT(S_i)$   
  return  $DecisionTree(node : Split, descendants : (t_1, t_2, \dots t_s))$ 
```

Pomembne komponente algoritma *TDIDT*

- *Partition*(S , *Split*): test *Split* in razbitje množice S
- *Impurity*(S): nečistoča množice S
- *SelectOptimal*(S): izbira optimalnega testa za množico S

Testi in razbitje množice $Partition(S, Split)$

Diskretna spremenljivka $X_j, D_j = \{v_1, v_2, \dots, v_m\}$

- ① *Split* X_j : $S_i = \{(\mathbf{x}, y) \in S : x_j = v_i\}$, en možen test
- ② *Split* $X_j \in V, V \subset D_j, V \neq \emptyset$: $S_1 = \{(\mathbf{x}, y) \in S : x_j \in V\}$,
 $S_2 = S \setminus S_1, (2^{|D_j(S)|} - 2)/2 = 2^{|D_j(S)|-1} - 1$ možnih testov

Numerična spremenljivka $X_j, D_j \subseteq \mathbb{R}$

Split $X_j < v$: $S_1 = \{(\mathbf{x}, y) \in S : x_j < v\}$, $S_2 = S \setminus S_1, |D_j(S)| - 1$ možnih testov (vrednosti praga v)

$D_j(S) \subseteq D_j$ je množica vrednosti X_j v množici S .

Napoved končnega vozlišča $leaf : S$

Regresija, $D_Y \subseteq \mathbb{R}$: povprečje

$$Prediction(leaf : S) = \frac{1}{|S|} \sum_{(x,y) \in S} y$$

Klasifikacija, $D_Y = \{v_1, v_2, \dots, v_c\}$: večinski razred

$$Prediction(leaf : S) = \arg \max_{v_i \in D_Y} p(Y = v_i | S)$$

$p(Y = v_i | S)$ je verjetnost, da primer iz množice S pripada razredu v_i .

Funkcija nečistoče $Impurity(S)$

Funkcija nečistoče meri varianco vrednosti ciljne spremenljivke Y v S .

Regresija, $D_Y \subseteq \mathbb{R}$

$$Impurity(S) = \frac{1}{|S|} \sum_{(x,y) \in S} (y - \bar{y})^2, \quad \bar{y} = \frac{1}{|S|} \sum_{(x,y) \in S} y$$

Klasifikacija, $D_Y = \{v_1, v_2, \dots, v_c\}$

$$Impurity(S) = \phi(p_1, p_2, \dots, p_c)$$


Verjetnosti $p_i = p(Y = v_i | S)$

Zaželeni lastnosti funkcije nečistoče $\phi(p_1, p_2, \dots, p_c)$

- 1 Doseže maksimalno vrednost pri enakomerni porazdelitvi $\forall i : p_i = 1/c$
- 2 Doseže minimalno vrednost pri porazdelitvah, kjer $\exists i : p_i = 1$
- 3 Simetrična: neobčutljiva na vrstni red parametrov
- 4 Konkavna, zvezna in zvezno odvedljiva

Dve pogosto uporabljani funkciji

- 1 Entropija $\phi = -\sum_{i=1}^c p_i \log_2 p_i$, dokaz prvih dveh lastnosti na tabli
- 2 Indeks Gini $\phi = 1 - \sum_{i=1}^c p_i^2$, dokaz prvih dveh lastnosti doma



Izbira optimalnega testa $Split = SelectOptimal(S)$

Ciljna funkcija za optimizacijo zmanjšanje nečistoče IR

$$IR(Split, S) = Impurity(S) - \sum_{i=1}^s \frac{|S_i|}{|S|} Impurity(S_i)$$

- Test $Split$ povzroči razbitje S na $\{S_1, S_2, \dots, S_s\}$
- $IR = Impurity Reduction$

Test izberemo z optimizacijo

$$\max_{Split} IR(Split, S) \equiv \min_{Split} \sum_{i=1}^s |S_i| Impurity(S_i)$$

Optimizacijski algoritmi za izbiro testa

- 1 Naštejemo vse možne teste
- 2 Vzorčimo množico vseh možnih testov

Ali lahko prepoznam delfina?

primer	dolzina	skрге	kljun	zob	delfin
x ₁	3	ne	da	veliko	da
x ₂	4	ne	da	veliko	da
x ₃	3	ne	da	malo	da
x ₄	5	ne	da	veliko	da
x ₅	5	ne	da	malo	da
x ₆	5	da	da	veliko	ne
x ₇	4	da	da	veliko	ne
x ₈	5	da	ne	veliko	ne
x ₉	4	da	ne	veliko	ne
x ₁₀	4	ne	da	malo	ne

Opis naloge strojnega učenja

Primeri

10 opazovanih živali, od tega 5 delfinov

Spremenljivke

- Ciljna spremenljivka $Y = \text{deflin}$, $D_Y = \{da, ne\}$
- Ena numerična napovedna spremenljivka $X_1 = \text{dolzina}$, $D_1 = \mathbb{R}^+$
- Tri diskretne napovedne spremenljivke
 - $X_2 = \text{skрге}$, $D_2 = \{da, ne\}$
 - $X_3 = \text{kljun}$, $D_2 = \{da, ne\}$
 - $X_4 = \text{zob}$, $D_2 = \{veliko, malo\}$

Napovedni model, ki razpozna delfine: klasifikacijsko drevo

Nečistost prvotne množice in možni testi

$Impurity(S), S = \{x_1, x_2, \dots, x_{10}\}$

- $p(delfin = da) = p(delfin = ne) = 5/10 = 0.5$
- $Gini(S) = 1 - (0.5^2 + 0.5^2) = 0.5$

Pet možnih testov

- 1 $dolzina < 4$
- 2 $dolzina < 5$
- 3 $skрге$
- 4 $kljun$
- 5 zob

Test *dolzina* < 4

$Impurity(S_1), S_1 = \{x_1, x_3\}$

- $p(delfin = da) = 2/2 = 1, p(delfin = ne) = 0/2 = 0$
- $Gini(S_1) = 1 - (1^2 + 0^2) = 0$

$Impurity(S_2), S_2 = \{x_2, x_4, x_5, x_6, x_7, x_8, x_9, x_{10}\}$

- $p(delfin = da) = 3/8 = 0.375, p(delfin = ne) = 5/8 = 0.625$
- $Gini(S_2) = 1 - (0.375^2 + 0.625^2) = 0.46875$

$$IR(dolzina < 4) = 0.5 - \left(\frac{2}{10} 0 + \frac{8}{10} 0.46875 \right) = 0.125$$

Test *dolzina* < 5

$Impurity(S_1), S_1 = \{x_1, x_2, x_3, x_7, x_9, x_{10}\}$

- $p(delfin = da) = 3/6 = 0.5, p(delfin = ne) = 3/6 = 0.5$
- $Gini(S_1) = 1 - (0.5^2 + 0.5^2) = 0.5$

$Impurity(S_2), S_2 = \{x_4, x_5, x_6, x_8\}$

- $p(delfin = da) = 2/4 = 0.5, p(delfin = ne) = 2/4 = 0.5$
- $Gini(S_2) = 1 - (0.5^2 + 0.5^2) = 0.5$

$$IR(dolzina < 5) = 0.5 - \left(\frac{6}{10}0.5 + \frac{4}{10}0.5\right) = 0$$

Test skрге

$Impurity(S_1), S_1 = \{x_6, x_7, x_8, x_9\}$

- $p(delfin = da) = 0/4 = 0, p(delfin = ne) = 4/4 = 1$
- $Gini(S_1) = 1 - (0^2 + 1^2) = 0$

$Impurity(S_2), S_2 = \{x_1, x_2, x_3, x_4, x_5, x_{10}\}$

- $p(delfin = da) = 5/6 = 0.833, p(delfin = ne) = 1/6 = 0.167$
- $Gini(S_2) = 1 - (0.833^2 + 0.167^2) = 0.278$

$$IR(skrge) = 0.5 - \left(\frac{4}{10} 0 + \frac{6}{10} 0.278 \right) = 0.333$$

Test *kljun*

$$\text{Impurity}(S_1), S_1 = \{x_1, x_2, x_3, x_4, x_5, x_6, x_7, x_{10}\}$$

- $p(\text{delfin} = da) = 5/8 = 0.625$, $p(\text{delfin} = ne) = 3/8 = 0.375$
- $\text{Gini}(S_1) = 1 - (0.625^2 + 0.375^2) = 0.46875$

$$\text{Impurity}(S_2), S_2 = \{x_8, x_9\}$$

- $p(\text{delfin} = da) = 0/2 = 0$, $p(\text{delfin} = ne) = 2/2 = 1$
- $\text{Gini}(S_2) = 1 - (0^2 + 1^2) = 0$

$$\text{IR}(\text{kljun}) = 0.5 - \left(\frac{8}{10} 0.46875 + \frac{2}{10} 0 \right) = 0.125$$

Test zob

$$\text{Impurity}(S_1), S_1 = \{x_1, x_2, x_4, x_6, x_7, x_8, x_9\}$$

- $p(\text{delfin} = da) = 3/7 = 0.4286$, $p(\text{delfin} = ne) = 4/7 = 0.5714$
- $Gini(S_1) = 1 - (0.4286^2 + 0.5714^2) = 0.4898$

$$\text{Impurity}(S_2), S_2 = \{x_3, x_5, x_{10}\}$$


- $p(\text{delfin} = da) = 2/3 = 0.667$, $p(\text{delfin} = ne) = 1/3 = 0.333$
- $Gini(S_2) = 1 - (0.667^2 + 0.333^2) = 0.444$

$$IR(\text{zob}) = 0.5 - \left(\frac{7}{10} 0.4898 + \frac{3}{10} 0.444 \right) = 0.0238$$


Izbira optimalnega testa: *skрге*

- ❶ *dolzina* < 4: 0.125
- ❷ *dolzina* < 5: 0
- ❸ *skрге*: **0.333**
- ❹ *kljun*: 0.125
- ❺ *zob*: 0.0238

Delni rezultat



Končno vozlišče



Rekurzija: nečistost množice in možni testi

$Impurity(S), S = \{x_1, x_2, x_3, x_4, x_5, x_{10}\}$


- $p(delfin = da) = 5/6 = 0.833, p(delfin = ne) = 1/6 = 0.167$
- $Gini(S) = 1 - (0.833^2 + 0.167^2) = 0.278$

Štirje možni testi

- 1 $dolzina < 4$
- 2 $dolzina < 5$
- 3 $kljun$
- 4 zob

Končni rezultat

Legenda: *skрге = b* pomeni *skрге = ne*, *zob = b* pomeni *zob = veliko*



Kontrola pristranskosti in variance

Velikost drevesa

- Kontroliramo tako, da dopuščamo $Impurity > 0$ v končnih vozliščih
- Rezanje dreves

Sprotno in naknadno rezanje dreves

- Sprotno: navzdol omejimo število primerov v (končnih) vozliščih (parameter `minsplit`, ms)
- Naknadno: pretvarjanje notranjih vozlišč v končna v rezultatu algoritma TDIDT (parameter stopnja rezanja, α ali cp)

Naknadno rezanje dreves

Rezanje poddrevesa v vozlišču t

Notranje vozlišče t spremenimo v končno vozlišče t_L .

Napaka poddrevesa t

$$Err_{\alpha}(t) = Err(t) + \alpha|t|$$

- $Err(t)$: napaka poddrevesa v t na učnih primerih iz t
- $|t|$: število končnih vozlišč, ki so nasledniki t

Odločitev o rezanju: $Err_{\alpha}(t_L) \leq Err_{\alpha}(t)$

Parameter α : regulator moči, stopnja rezanja (R implementacija: *cp*)

Primer rezanja poddrevesa $Err(t : dolzina < 3.5)$

Napaka poddrevesa

$Err_{\alpha}(t) = 0 + 3\alpha$, poddrevo ima napako 0 in tri končna vozlišča.


Napaka končnega vozlišča

$Err_{\alpha}(t_L) = 1/3 + 1\alpha$, učni primeri $\{x_3, x_5, x_{10}\}$: dva pozitivna in en negativen (napaka 1/3).

Prelomna točka $Err_{\alpha}(t) = Err_{\alpha}(t_L)$

Če je $\alpha \geq 1/6$, potem bo poddrevo porezano; sicer pa ne.

Legenda: $skрге = b$
 pomeni $skрге = ne$,
 $zob = b$ pomeni
 $zob = veliko$



Primer rezanja poddrevesa $Err(t : zob \in \{veliko\})$

Napaka poddrevesa

$Err_{\alpha}(t) = 0 + 4\alpha$, poddrevo ima napako 0 in štiri končna vozlišča.


Napaka končnega vozlišča

$Err_{\alpha}(t_L) = 1/6 + 1\alpha$, šest učnih primerov: pet pozitivnih in en negativen (napaka $1/6$).

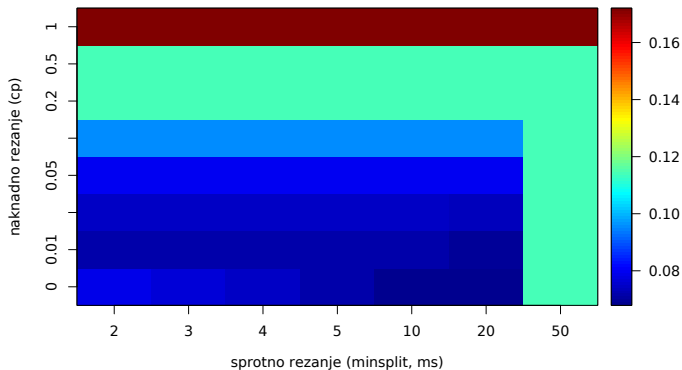
Prelomna točka $Err_{\alpha}(t) = Err_{\alpha}(t_L)$

Če je $\alpha \geq 1/18$, potem bo poddrevo porezano; sicer pa ne.

Legenda: $skrg = b$
 pomeni $skrg = ne$,
 $zob = b$ pomeni
 $zob = veliko$



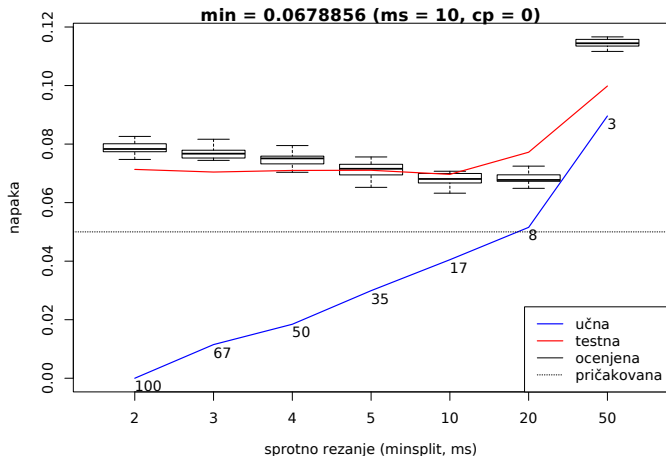
Regresijska drevesa: *ms* in *cp*



$$Y = (1 + X_1 + X_1 X_2)/3 + \mathcal{N}(0, 0.05), D_i = [0, 1], i = 1..2, D_Y = [0, 1]$$


Regresijska drevesa ($cp = 0$): ms

Številke: število končnih vozlišč v drevesu



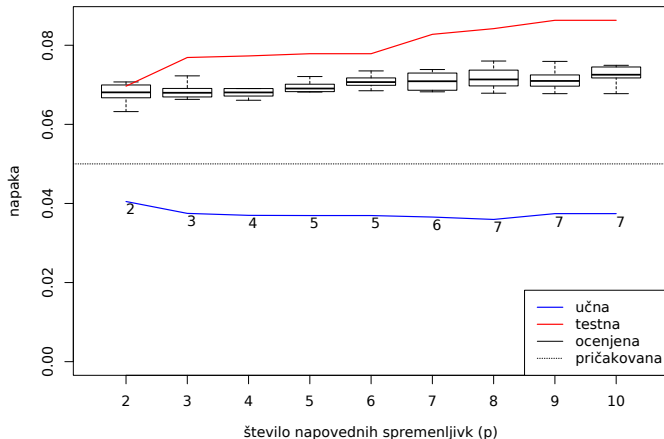
Regresijska drevesa ($ms = 10$): cp

Številke: število končnih vozlišč v drevesu




Regresijska drevesa: število napovednih spremenljivk

Številke: število napovednih spremenljivk v drevesu




Klasifikacijska drevesa: *ms* in *cp*



$Y = I((1 + X_1 + X_1 X_2)/3 \geq 0.5)$, $D_i = [0, 1]$, $i = 1..2$, $D_Y = \{0, 1\}$
 zamenjamo vrednost Y 0.05 naključno izbranim primerom


Klasifikacijska drevesa ($cp = 0.02$): *ms*

Številke: število končnih vozlišč v drevesu




Klasifikacijska drevesa ($ms = 5$): cv

Številke: število končnih vozlišč v drevesu



Klasifikacijska drevesa: število napovednih spremenljivk

Številke: število napovednih spremenljivk v drevesu



Časovna zahtevnost algoritmov za učenje dreves

Učenje drevesa iz podatkovne množice S

- Eno vozlišče: $O(p|S|)$, p je število napovednih spremenljivk
- Celotno drevo: $O(p|S| \log |S|)$, ker je $\log |S|$ pričakovana globina

Naknadno rezanje

- Eno vozlišče: $O(\log |S|)$
- Celotno drevo: $O(\log |S| \log |S|)$

Znani algoritmi in implementacije

CART (Breiman in ost. 1984)

Na voljo knjižnica za R.

C4.5 (Quinlan 1995), pozneje C5.0

Na voljo v zbirki Weka kot J4.8 (C4.5), na voljo knjižnica za R (C5.0).

Kaj so odločitvena pravila?

Eno pravilo r : *IF Pogoj THEN Napoved*

- Pogoj je konjunkcija testov napovednih spremenljivk X ,
npr. $X_1 > 3 \wedge X_3 = ne$
- Napoved poda napovedano vrednost ciljne spremenljivke Y ,
npr. $\hat{Y} = da$

Urejena (tudi zveržena) množica pravil

Napoved za \mathbf{x} poda prvo pravilo r , za katerega velja: $Pogoj(\mathbf{x}) = True$.

Neurejena množica pravil

Napovedi za \mathbf{x} podajo vsa pravila r , za katera velja $Pogoj(\mathbf{x}) = True$, množica napove povprečje (regresija) ali večinsko napoved (klasifikacija).

Primeri množice pravil

Urejena množica pravil

IF skрге = da THEN delfin = ne ELSE
IF zob = veliko THEN delfin = da ELSE
IF dolzina = 4 THEN delfin = ne ELSE
delfin = da

Neurejena množica pravil

IF dolzina = 3 THEN delfin = da
IF skрге = ne \wedge zob = veliko THEN delfin = da

Učenje enega pravila $LearnRule(S) = DecisionRule$

```
function  $LearnRule(S)$   
   $Cond = True$   
  while  $Impurity(S, Cond) > 0$  do  
     $L_{opt} = \arg \min_L Impurity(S, Cond \wedge L)$   
     $Cond = Cond \wedge L_{opt}$   
  return  $DecisionRule : IF Cond THEN Y = Prediction(S, Cond)$ 
```

Napoved pravila $Class(S, Cond)$

$$S_{Cond} = \{(\mathbf{x}, y) \in S : Cond(\mathbf{x}) = True\}$$

Regresija, $D_Y \subseteq \mathbb{R}$: povprečje

$$Prediction(S, Cond) = \frac{1}{|S|} \sum_{(\mathbf{x}, y) \in S_{Cond}} y$$

Klasifikacija, $D_Y = \{v_1, v_2, \dots, v_c\}$: večinski razred

$$Prediction(S, Cond) = \arg \max_{v \in D_Y} p(Y = v | S_{Cond})$$

Funkcija nečistoče $Impurity(S, Cond)$

Funkcija nečistoče meri varianco vrednosti ciljne spremenljivke Y v množici pokritih primerov $S_{Cond} = \{(\mathbf{x}, y) \in S : Cond(\mathbf{x}) = True\}$.

Regresija, $D_Y \subseteq \mathbb{R}$

$$Impurity(S, Cond) = \frac{1}{|S|} \sum_{(\mathbf{x}, y) \in S_{Cond}} (y - \bar{y})^2$$

Klasifikacija, $D_Y = \{v_1, v_2, \dots, v_c\}$

$$Impurity(S, Cond) = 1 - \max_{v \in D_Y} p(Y = v | S_{Cond})$$

Prekrivni algoritem $Covering(S) = RuleSet$

Za učenje urejene množice pravil

```
function Covering(S)  
  RuleSet = []  
  while  $S \neq \emptyset$  do  
    Rule = LearnRule(S)  
     $S = S \setminus S_{Rule.Cond}$   
    append Rule to RuleSet  
  return RuleSet
```

Spremembe za neurejene množice pravil

- V vsaki iteraciji izberemo razred v za katerega se učimo pravilo
- Posebna varianta $LearnRule(S, v)$, ki se uči pravilo za izbran razred v
- $S = S \setminus S_{Rule.Cond} \wedge Y=v$

Ali lahko prepoznam delfina?

primer	dolzina	skрге	kljun	zob	delfin
x ₁	3	ne	da	veliko	da
x ₂	4	ne	da	veliko	da
x ₃	3	ne	da	malo	da
x ₄	5	ne	da	veliko	da
x ₅	5	ne	da	malo	da
x ₆	5	da	da	veliko	ne
x ₇	4	da	da	veliko	ne
x ₈	5	da	ne	veliko	ne
x ₉	4	da	ne	veliko	ne
x ₁₀	4	ne	da	malo	ne

Prva iteracija algoritma $LearnRule(S)$

Na začetku $Cond = True$, $S = \{x_1, x_2, \dots, x_{10}\}$

L	S_{Cond}	p_{da}	p_{ne}	$Impurity(S, Cond)$
$dolzina = 3$	$\{x_1, x_3\}$	1	0	0
$dolzina = 4$	$\{x_2, x_6, x_9, x_{10}\}$	0.25	0.75	0.25
$dolzina = 5$	$\{x_4, x_5, x_6, x_8\}$	0.5	0.5	0.5
$skрге = da$	$\{x_6, x_7, x_8, x_9\}$	0	1	0
$skрге = ne$	$\{x_1, \dots, x_5, x_{10}\}$	0.83	0.17	0.17
$kljun = da$	$\{x_1, \dots, x_7, x_{10}\}$	0.625	0.375	0.375
$kljun = ne$	$\{x_8, x_9\}$	0	1	0
$zob = veliko$	$\{x_1, x_2, x_4, x_6, \dots, x_9\}$	0.43	0.57	0.43
$zob = malo$	$\{x_3, x_5, x_{10}\}$	0.67	0.33	0.33

Prva iteracija algoritma *Covering*(S)

Izbrano pravilo *IF skрге = da THEN delfin = ne*

- Ker od vseh pravil z *Impurity* = 0 pokrije največ primerov (4)
- Ostane torej šest primerov $S = \{x_1, \dots, x_5, x_{10}\}$

Prva iteracija algoritma *LearnRule(S)*, drugič

Na začetku $Cond = True$, $S = \{x_1, \dots, x_5, x_{10}\}$

L	S_{Cond}	p_{da}	p_{ne}	$Impurity(S, Cond)$
$dolzina = 3$	$\{x_1, x_3\}$	1	0	0
$dolzina = 4$	$\{x_2, x_{10}\}$	0.5	0.5	0.5
$dolzina = 5$	$\{x_4, x_5\}$	1	0	0
$kljun = da$	$\{x_1, \dots, x_5, x_{10}\}$	0.83	0.17	0.17
$kljun = ne$	\emptyset	NaN	NaN	NaN
$zob = veliko$	$\{x_1, x_2, x_4\}$	1	0	0
$zob = malo$	$\{x_3, x_5, x_{10}\}$	0.67	0.33	0.33

Druga iteracija algoritma *Covering*(S)

Izbrano pravilo *IF zob = veliko THEN delfin = da*

- Pokriva tri primere
- Ostanejo trije primeri $S = \{x_3, x_5, x_{10}\}$

Trenutna (urejena) množica pravil

IF skрге = da THEN delfin = ne ELSE
IF zob = veliko THEN delfin = da

Prva iteracija algoritma $LearnRule(S)$, tretjič

Na začetku $Cond = True$, $S = \{x_3, x_5, x_{10}\}$

L	S_{Cond}	p_{da}	p_{ne}	$Impurity(S, Cond)$
$dolzina = 3$	$\{x_3\}$	1	0	0
$dolzina = 4$	$\{x_{10}\}$	0	1	0
$dolzina = 5$	$\{x_5\}$	1	0	0
$kljun = da$	$\{x_3, x_5, x_{10}\}$	0.67	0.33	0.33
$kljun = ne$	\emptyset	NaN	NaN	NaN

Tretja iteracija algoritma *Covering(S)*

Izbrano pravilo *IF dolzina = 4 THEN delfin = ne*

- Pokriva en primer
- Ostaneta dva pozitivna primera $S = \{x_3, x_5\}$, čista množica

Končna (urejena) množica pravil

```

IF skрге = da    THEN delfin = ne  ELSE
IF zob = veliko THEN delfin = da   ELSE
IF dolzina = 4   THEN delfin = ne  ELSE
delfin = da
  
```

Kontrola pristranskosti in variance

Velikost množice pravil

- število pravil
- število testov v pravilih

Kontrola velikosti

- 1 Sprotno rezanje: predčasni izhod iz iteracije *LearnRule*
- 2 Naknadno rezanje: odstranjevanje pravil ali posameznih testov

Znani algoritmi in implementacije

CN2 (Clark and Nibblet 1987)

Na voljo knjižnica za R.

Ripper (Cohen 1995)

Na voljo v zbirki Weka, za uporabo v R na voljo skozi knjižnico RWeka.